

Actividad06b

January 28, 2026

1 Informe: Uso del Factoreo de Matrices en Transformers

- Asignatura: Metodos Numericos
- Estudiante: Luis Lema
- Tema: Optimización de modelos Transformers mediante factorización matricial
- Link Repositorio: https://github.com/LuisALema/Metodos_Numericos_2025B/tree/main/TareasExtras/A

1.1 Introducción

Los modelos Transformers utilizan grandes matrices de pesos para procesar secuencias. Estas matrices pueden ser muy costosas en memoria y tiempo de cómputo. El factoreo de matrices permite descomponer estas matrices en factores más pequeños, reduciendo costos sin afectar significativamente la precisión del modelo.

1.2 Objetivo

Explicar el uso del factoreo de matrices dentro de la arquitectura Transformer, indicando sus principales razones y ventajas en modelos de redes neuronales profundas.

1.3 ¿Qué es el factoreo de matrices?

El factoreo de matrices consiste en descomponer una matriz grande en el producto de dos o más matrices de menor dimensión, conservando la información principal. Ejemplos comunes son SVD, factorización de bajo rango y descomposición matricial.

1.4 Uso de matrices en Transformers

En los Transformers, las matrices aparecen en: - Proyecciones Q, K y V en la atención. - Capas Feed Forward. - Matrices de embeddings. Estas matrices suelen tener millones de parámetros.

1.5 Razón 1: Reducción de parámetros

El factoreo permite representar una matriz grande como el producto de dos matrices pequeñas, reduciendo drásticamente el número de pesos del modelo.

1.6 Razón 2: Aceleración del entrenamiento

Menos parámetros implican menos multiplicaciones matriciales, lo que disminuye el tiempo de entrenamiento y el consumo de energía.

1.7 Razón 3: Menor uso de memoria

El modelo ocupa menos memoria en GPU o RAM, permitiendo entrenar modelos grandes en hardware más limitado.

1.8 Ventaja 1: Eficiencia computacional

Las operaciones se vuelven más rápidas y ligeras, mejorando el rendimiento general del sistema.

1.9 Ventaja 2: Regularización implícita

El bajo rango actúa como una forma de regularización, reduciendo el sobreajuste del modelo.

1.10 Ventaja 3: Modelos más escalables

Permite construir Transformers más grandes sin que el costo computacional crezca de forma exponencial.

1.11 Conclusión

El factorización de matrices es una técnica clave para hacer los Transformers más eficientes, rápidos y escalables, sin sacrificar notablemente su precisión.

1.12 Recomendación Final

Se recomienda aplicar factorización de bajo rango en arquitecturas grandes para optimizar recursos y mejorar la viabilidad del modelo en producción.