

Actividad07_b

January 28, 2026

1 Informe: Diferencias entre las arquitecturas Hopper y Blackwell

- Asignatura: Metodos Numericos
- Estudiante: Luis Lema
- Tema: Comparación de arquitecturas GPU para IA
- Link Repositorio: https://github.com/LuisALema/Metodos_Numericos_2025B/tree/main/TareasExtras/A

1.1 Introducción

Las arquitecturas Hopper y Blackwell de NVIDIA representan dos generaciones de GPUs diseñadas para acelerar cargas de trabajo de inteligencia artificial, cómputo científico y aprendizaje profundo. Estas arquitecturas priorizan el rendimiento, la eficiencia energética y el soporte para múltiples representaciones numéricas.

1.2 Objetivo

Analizar las diferencias principales entre Hopper y Blackwell, así como el impacto de los formatos numéricos en el rendimiento de modelos de IA.

1.3 Arquitectura Hopper

Hopper (H100) introdujo Tensor Cores de cuarta generación, soporte para TF32 y optimización para entrenamiento de modelos grandes. Está orientada a centros de datos y supercómputo.

1.4 Arquitectura Blackwell

Blackwell (B100/B200) es la evolución de Hopper. Incorpora Tensor Cores más eficientes, mayor ancho de banda y soporte extendido para formatos de baja precisión.

1.5 Diferencia entre FP32 y TF32

FP32 (32 bits) usa una mantisa completa, dando máxima precisión.

TF32 (19 bits efectivos) reduce la precisión para acelerar operaciones en IA, manteniendo un error aceptable.

1.6 Representaciones numéricas soportadas

Ambas arquitecturas soportan:

- FP64: alta precisión científica
- FP32: precisión estándar
- TF32: entrenamiento acelerado

- FP16 / BF16: entrenamiento rápido
- INT8 / INT4: inferencia eficiente

1.7 Preferencia por menor precisión

Los modelos de IA toleran errores pequeños. Reducir precisión permite: - Más operaciones por segundo - Menor consumo de energía - Menor uso de memoria

1.8 Ventajas clave de Blackwell sobre Hopper

- Mayor rendimiento por watt
- Mejor soporte para INT y FP16
- Más eficiencia en modelos gigantes

1.9 Conclusión

Blackwell mejora a Hopper en velocidad, eficiencia y manejo de formatos numéricos de baja precisión, haciendo posible entrenar modelos de IA mucho más grandes y rápidos.